

基于 NSGA-II 多目标优化的 CNN-BiLSTM 风速预测模型

王晨淇

2025 年 11 月 23 日

1 问题描述

风速作为典型的非线性、非平稳时序数据，其变化受地形、气候等多因素耦合影响，表现出强波动性与复杂的时空关联性。精准的风速预测是风力发电调度、电网稳定运行及能源规划的关键前提。现有风速预测模型存在以下局限性：(1) 单一目标优化策略仅关注预测精度的提升，易导致模型结构冗余及参数规模过大；(2) 单一网络结构难以同时兼顾局部特征提取与长程时序依赖捕捉能力。

本文提出一种基于 NSGA-II 算法的多目标优化 CNN-BiLSTM 风速预测模型，。优化目标可定义为：

$$\begin{aligned} \min_{\mathbf{x} \in S} \quad & \begin{cases} f_1(\mathbf{x}) = \text{RMSE}(\mathbf{x}) = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2} \\ f_2(\mathbf{x}) = \text{Complexity}(\mathbf{x}) = \sum_{l=1}^L \text{Param}_l(\mathbf{x}) \end{cases} \\ \text{s.t.} \quad & \text{Complexity}(\mathbf{x}) \leq C_{\max} \end{aligned} \quad (1)$$

其中 f_1 为预测误差目标， y_i 和 $\hat{y}_i$ 分别表示第 i 个样本的真实风速与预测值； f_2 为模型复杂度目标， Param_l 表示第 l 层的可训练参数数量； $C_{\max} = 10^7$ 为预设的模型复杂度上限。

针对风速预测场景，设数据集 $D = \{D_{\text{train}}, D_{\text{val}}, D_{\text{test}}\}$ ，模型自动化设计问题可等价于对决策变量 $\mathbf{x}$ 的搜索问题。**决策变量**（共 39 维）定义为：

$$\mathbf{x} = (t; C_1; C_2; C_3; L_1; L_2; \alpha) \quad (2)$$

各分量说明如下：

- **训练超参数** $t \in \mathbb{R}^4$ ：

- $t_1 \in [0, 3]$ ：Batch size 指数，映射为 $\{32, 64, 96, 128\}$

- $t_2 \in [0, 3]$: 优化器类型 (0: SGD, 1: Adam, 2: AdaDelta, 3: RMSprop)
- $t_3 \in [10^{-4}, 10^{-2}]$: 学习率, 设置为连续值
- $t_4 \in [0, 3]$: 正则化方式 (0: None, 1: L1, 2: L2, 3: L1&L2)
- **CNN 模块参数** $C_i \in \mathbb{R}^5, i = 1, 2, 3$
 - $c_{i,1} \in [0, 7]$: 卷积核数量指数, 实际卷积核数 = $16(c_{i,1} + 1)$
 - $c_{i,2} \in [0, 3]$: 卷积核尺寸指数, 实际尺寸 = $2c_{i,2} + 3$
 - $c_{i,3} \in [0, 7]$: 激活函数类型 (0: Softplus, 1: Softsign, 2: ELU, 3: Softmax, 4: Sigmoid, 5: Tanh, 6: ReLU, 7: 无激活函数)
 - $c_{i,4} \in [0, 2]$: 池化类型 (0: MaxPool, 1: AvgPool, 2: 无)
 - $c_{i,5} \in [0, 3]$: 池化窗口指数, 实际尺寸 = $2c_{i,5} + 3$
- **BiLSTM 模块参数** $L_j \in \mathbb{R}^4, j = 1, 2$
 - $l_{j,1} \in [0, 7]$: 隐藏层维度指数, 实际隐藏单元数 = $16(l_{j,1} + 1)$
 - $l_{j,2} \in [0, 3]$: 网络层数指数, 实际层数 = $l_{j,2} + 1$
 - $l_{j,3} \in [0, 7]$: 激活函数类型 (0: Softplus, 1: Softsign, 2: ELU, 3: Softmax, 4: Sigmoid, 5: Tanh, 6: ReLU, 7: 无)
 - $l_{j,4} \in [0, 3]$: Dropout 指数, 实际 Dropout 率 = $0.1 \times l_{j,4}$
- **网络拓扑参数** $\alpha \in \{0, 1\}^{10}$:

本研究采用 NSGA-II 算法同时优化上述两个冲突目标, 以获得在预测精度与模型轻量化之间达到权衡的 Pareto 折衷解。

2 基于 NSGA-II 多目标优化的 CNN-BiLSTM 风速预测模型

2.1 方法框架与问题建模

2.1.1 NSGA-II-CNN-BiLSTM 方法总体框架

NSGA-II-CNN-BiLSTM 的总体流程遵循标准 NSGA-II 范式, 主要超参数设置为: 种群规模 $N = 40$, 最大进化代数 $G = 60$, 交叉概率 $p_c = 0.8$, 变异概率 $p_m = 0.09$ 。算法流程如下:

Algorithm 1 NSGA-II 优化的 CNN-BiLSTM 模型搜索

-
- 1: 初始化种群 P_0 , 每个个体随机生成 39 维编码向量
 - 2: **for** 代数 $g = 1$ 至 G **do**
 - 3: 评估种群 P_{g-1} : 解码每个个体, 训练对应模型至多 200 轮 (早停 patience= 5), 计算 RMSE 和复杂度
 - 4: 对 P_{g-1} 进行快速非支配排序, 得到各个体等级 $rank_i$
 - 5: 计算拥挤度距离 cd_i , 保持种群多样性
 - 6: 采用二元锦标赛选择生成交配池 M_g
 - 7: 对 M_g 执行单点交叉操作 (概率 0.8), 产生子代 C_g
 - 8: 对 C_g 执行变量长度变异操作 (概率 0.09), 得到变异子代 C'_g
 - 9: 合并种群 $R_g = P_{g-1} \cup C'_g$ (规模 $2N$)
 - 10: 对 R_g 进行环境选择, 基于 $rank$ 和 cd 筛选最优 N 个个体构成 P_g
 - 11: **end for**
 - 12: 返回最终代 P_G 的 Pareto 最优解集
-

2.2 混合编码方案与种群初始化

2.2.1 编码策略

NSGA-II-CNN-BiLSTM 采用**混合编码策略**, 每个个体表示为 39 维浮点数向量:

$$\text{Ind}_i = [x_1, x_2, \dots, x_{39}], \quad x_j \in [lb_j, ub_j] \quad (3)$$

其中各维度分配如表 1 所示。

表 1: 混合编码方案维度分配


区域	维度范围	长度	描述
拓扑结构	x_1-x_{10}	10	5 模块连接关系
CNN 参数	$x_{11}-x_{25}$	15	3 个 CNN 模块, 每模块 5 维
LSTM 参数	$x_{26}-x_{35}$	10	2 个 BiLSTM 模块, 每模块 4 维
训练配置	$x_{36}-x_{39}$	4	Batch size、优化器、学习率、正则化

解码规则如下:

- **拓扑结构** (Topo): 网络架构参数 topo 由 10 位二进制编码组成, 其定义为 $\text{topo}=[bin_1, bin_2, \dots, bin_i, \dots, bin_{10}]$, $bin_i=\text{Randint}(0, 1)$, 其中 bin_i 表示 topo 内第 i 位二进制编码, $\text{Randint}(0, 1)$ 表示随机产生一个 0 到 1 范围内的整数。生成 topo 后, 按公式 (4-5) 所示, 将其 10 位二进制编码逐一赋值给一个大

小为 4×4 的上三角阵 A (前 3 层为 CNN 模型, 后 2 层为 BiLSTM 模型), 以表示神经网络模型的网络拓扑信息。网络拓扑的唯一起点为第一个卷积模块, 对 A 中第 i 行第 j 列元素 $a_{i,j}$, 如 $a_{i,j}=1$, 则代表网络中第 i 个模块与第 $j+1$ 个模块相连接, 否则代表两模块之间无直接连接。topo 编码转换为对应上三角阵和模型拓扑的过程如图所示。

$$A = \begin{bmatrix} bin_1 & bin_2 & bin_3 & bin_4 \\ 0 & bin_5 & bin_6 & bin_7 \\ 0 & 0 & bin_8 & bin_9 \\ 0 & 0 & 0 & bin_{10} \end{bmatrix}$$



• **CNN 模块参数** (每模块 5 维):

- $k_{\text{num}} \in [0, 7]$: 卷积核数量指数, 实际卷积核数 = $16 \times (k_{\text{num}} + 1)$
- $k_{\text{size}} \in [0, 3]$: 卷积核尺寸指数, 实际尺寸 = $2 \times k_{\text{size}} + 3$
- $k_{\text{act}} \in [0, 7]$: 激活函数类型 (0: Softplus, 1: Softsign, 2: ELU, 3: Softmax, 4: Sigmoid, 5: Tanh, 6: ReLU, 7: Identity)
- $p_{\text{type}} \in [0, 2]$: 池化类型 (0: MaxPool, 1: AvgPool, 2: Identity)
- $p_{\text{size}} \in [0, 3]$: 池化窗口指数, 实际尺寸 = $2 \times p_{\text{size}} + 3$

• **BiLSTM 模块参数** (每模块 4 维):

- $k_{\text{num}} \in [0, 7]$: 隐藏层维度指数, 实际隐藏单元数 = $16 \times (k_{\text{num}} + 1)$
- $l_{\text{num}} \in [0, 3]$: 网络层数指数, 实际层数 = $l_{\text{num}} + 1$
- $k_{\text{act}} \in [0, 7]$: 激活函数类型 (0: Softplus, 1: Softsign, 2: ELU, 3: Softmax, 4: Sigmoid, 5: Tanh, 6: ReLU, 7: 无)
- $p_{\text{dropout}} \in [0, 3]$: Dropout 指数, 实际 Dropout 率 = $0.1 \times p_{\text{dropout}}$

• **训练超参数** (4 维):

- $b_s \in [0, 3]$: Batch size 映射为 $\{32, 64, 96, 128\}$
- $o_{pt} \in [0, 3]$: 优化器类型 (0: SGD, 1: Adam, 2: AdaDelta, 3: RMSprop)
- $r \in [10^{-4}, 10^{-2}]$: 学习率, 连续值
- $r_{eg} \in [0, 3]$: 正则化方式 (0: None, 1: L1, 2: L2, 3: L1&L2)


2.3 遗传操作算子

2.3.1 交叉算子

采用**单点交叉**（One-point Crossover）策略进行父代选择和子代生成。具体步骤如下：

首先,通过二元锦标赛选择机制构建交配池 M_g 。该过程包括从父代种群中随机选出两个个体进行适应度比较,选择适应度较高的个体进入交配池。重复此过程直至交配池中包含 40 个父本个体。

接下来，对交配池中相邻的个体依次进行配对，记为 par_1 和 par_2 。对于每一对父本，生成一个在区间 $[0, 1)$ 内均匀分布的随机数 r 。如果 $r < 0.8$ ，则进一步生成一个在区间 $[1, 39]$ 内的随机整数 pc 作为交叉位点。利用该位点对 par_1 和 par_2 进行单点交叉，生成两个子代个体 $child_1$ 和 $child_2$ 。如果 $r \geq 0.8$ ，则不进行交叉操作，直接将父代个体复制为子代，即 $child_1 = par_1$ 且 $child_2 = par_2$ 。最后，对生成的子代个体进行有效性验证。图中展示了当交叉位点 $k = 15$ 时的交叉操作示例。



2.3.2 变异算子

采用**变量长度变异** (Variable-length Mutation), 以概率 $p_m = 0.09$ 对每个子代个体应用变异操作。

- 随机选择一个区域进行变异：拓扑（概率 1/3）、模块参数（概率 1/3）或训练配置（概率 1/3）。
- **拓扑变异**：生成新的 10 维随机二进制向量（每个位独立为 0 或 1），检查是否不同于原拓扑且个体有效（通过 `is_valid_individual` 验证），若无效则重复生成。
- **模块参数变异**：随机选择 CNN 或 BiLSTM 类型，再随机选择一个模块（CNN 有 3 个，BiLSTM 有 2 个），然后随机选择其 5 个参数之一，在参数定义域内生成不同于原值的新整数值。
- **训练配置变异**：随机选择 4 个配置参数之一（`batch_size` 指数 `bs`、`optimizer` 指数 `opt`、`learning_rate` `lr`、`regularizer` 指数 `reg`）：
 - * 若选中学习率 `lr`：从均匀分布 $\mathcal{U}(10^{-4}, 10^{-2})$ 采样新值，要求 $|l_{r,new} - l_{r,old}| > 10^{-5}$ ，若不满足则重复采样。
 - * 若选中其他离散参数：在参数定义域内随机选择不同于原值的整数。

2.4 折中最优解选择策略

在获得最终代 Pareto 最优解集 $\mathcal{P}$ 后，采用归一化欧氏距离选择折中解：

$$k^* = \arg \min_{k \in \mathcal{P}} \sqrt{\tilde{f}_1^{(k)^2} + \tilde{f}_2^{(k)^2}} \quad (4)$$

其中归一化目标值为：

$$\tilde{f}_1^{(k)} = \frac{f_1^{(k)} - \min f_1}{\max f_1 - \min f_1 + \epsilon}, \quad \tilde{f}_2^{(k)} = \frac{f_2^{(k)} - \min f_2}{\max f_2 - \min f_2 + \epsilon} \quad (5)$$

$\epsilon = 10^{-10}$ 为防止除零的微小常数。该策略选择的解位于 Pareto 前沿的 **knee** 区域，在误差与复杂度之间取得最佳平衡。在 PF 图中观察该策略选择的解是否能够实现两个指标的折中。如果认为选择的 perato 解不是最佳折中解。则手动在 Pareto 最优解集中选择兼顾风速预测精度与模型轻量化的 Pareto 最优解，并将其表征的 CNN-BiLSTM 模型作为风速预测最优模型。

3 实验设计与结果分析

3.1 实验设置

3.1.1 模型架构与训练配置

最终优化的 CNN-BiLSTM 模型采用 5 模块混合架构（3 个 CNN 模块 + 2 个 BiLSTM 模块），各模块参数通过 NSGA-II 自动搜索确定。关键训练配置包括：

- 最大训练轮次：20 轮（架构搜索阶段），200 轮（最终模型训练）
- 早停策略：Patience= 5（搜索），Patience= 10（最终训练）
- 梯度裁剪：Max norm= 1.0
- 模型复杂度约束：Complexity $\leq 10^7$ 参数

3.1.2 评估指标

模型性能通过以下指标综合评估：

- MAE, RMSE, MAPE：预测误差度量
- Pearson 相关系数 R ：线性相关性

3.2 性能对比分析

表 2展示了各模型在测试集上的性能指标。与其他手工设计模型相比具有优势。

表 2: 各模型性能对比

模型	MAE (m s^{-1})	RMSE (m s^{-1})	MAPE (%)	相关系数 R
CEEMDAN-LSTM	0.4557	0.5732	22.41	0.8917
CEEMDAN-LSTM	0.4787	0.6054	23.71	0.8784
RBF	0.8448	1.2456	17.55	0.7507
LSTM	0.4687	0.6617	7.80	0.9324
BP	0.4649	0.6448	7.84	0.9353
LSSVM	0.4825	0.6617	8.34	0.9300
Elman	0.4849	0.6586	8.58	0.9328
CNN-BiLSTM	0.4136(1)	0.5151(1)	8.29(3)	0.9877(1)




图 1: CNN-BiLSTM 模型性能综合报告

3.3 Pareto 前沿演化分析

图 2展示了 CNN-BiLSTM 模型在 60 代进化过程中的 Pareto 前沿动态变化。可以观察到：




图 2: CNN-BiLSTM 模型 Pareto 前沿演化过程（第 1, 5, 10, 20, 40, 60 代）

- **初始代 (第 1 代)**: 解分布分散, RMSE 普遍大于 1.2 ms^{-1} , 复杂度范围 $[5 \times 10^4, 3 \times 10^5]$
- **中期 (第 5-20 代)**: 前沿快速向低 RMSE 区域收敛, 复杂度下降 50% 以上
- **后期 (第 40-60 代)**: 前沿趋于稳定, 最终 Pareto 集包含多个非支配解, RMSE 范围 $[0.55, 0.75] \text{ ms}^{-1}$